Sprawozdanie: Zadanie 1 - Analiza zbioru Iris i klasyfikacja KNN

Imię i nazwisko: Kacper Gentek **Numer indeksu:** 119074 **Grupa:** PS3

1. Krótka analiza danych (EDA) Zbiór danych Iris składa się ze 150 próbek kwiatów podzielonych na 3 klasy (gatunki): setosa, versicolor oraz virginica. Każda próbka opisana jest za pomocą 4 cech numerycznych, określających wymiary płatków i działek kielicha. Zbiór jest idealnie zbalansowany (po 50 próbek na klasę) i nie posiada braków danych. Z powodu prostej struktury i wyraźnych różnic między przynajmniej jedną z klas (setosa) a pozostałymi, jest to doskonały zbiór do testowania algorytmów klasyfikacyjnych.

Do realizacji zadania wykorzystano implementacje funkcji oparte na kodzie z zajęć/kursu z wykorzystaniem biblioteki numpy (w tym podział na zbiór treningowy i testowy, obliczanie odległości euklidesowej, algorytm KNN oraz wyliczanie metryk). Biblioteka scikit-learn posłużyła jedynie do wczytania danych i redukcji wymiarów (tSNE) na potrzeby końcowej wizualizacji.

2. Metryki oceny modelu Zbiór podzielono na część treningową i testową w proporcji 70:30. Klasyfikację przeprowadzono za pomocą algorytmu K-Nearest Neighbors (KNN) zaimplementowanego na podstawie materiałów z kursu, przyjmując wartość k=3. Model osiągnął znakomite wyniki:

Ogólne Accuracy (Dokładność): 0.9778

Szczegółowe metryki dla poszczególnych klas:

- **Klasa 0 (Setosa):** Precision: 1.0000 | Recall: 1.0000 | F1-score: 1.0000
- **Klasa 1 (Versicolor):** Precision: 0.9444 | Recall: 1.0000 | F1-score: 0.9714
- **Klasa 2 (Virginica):** Precision: 1.0000 | Recall: 0.9444 | F1-score: 0.9714

Model bezbłędnie sklasyfikował klasę setosa. Drobne pomyłki (na poziomie ok. 2-3%) wynikły ze zjawiska naturalnego nakładania się na siebie cech gatunków versicolor i virginica, co jest standardem dla tego zbioru.

3. Wizualizacja t-SNE po klasyfikacji Poniższy wykres 2D przedstawia zbiór testowy po redukcji 4 wymiarów za pomocą algorytmu t-SNE. Kolory punktów odpowiadają klasom przewidzianym przez zaimplementowany model KNN.

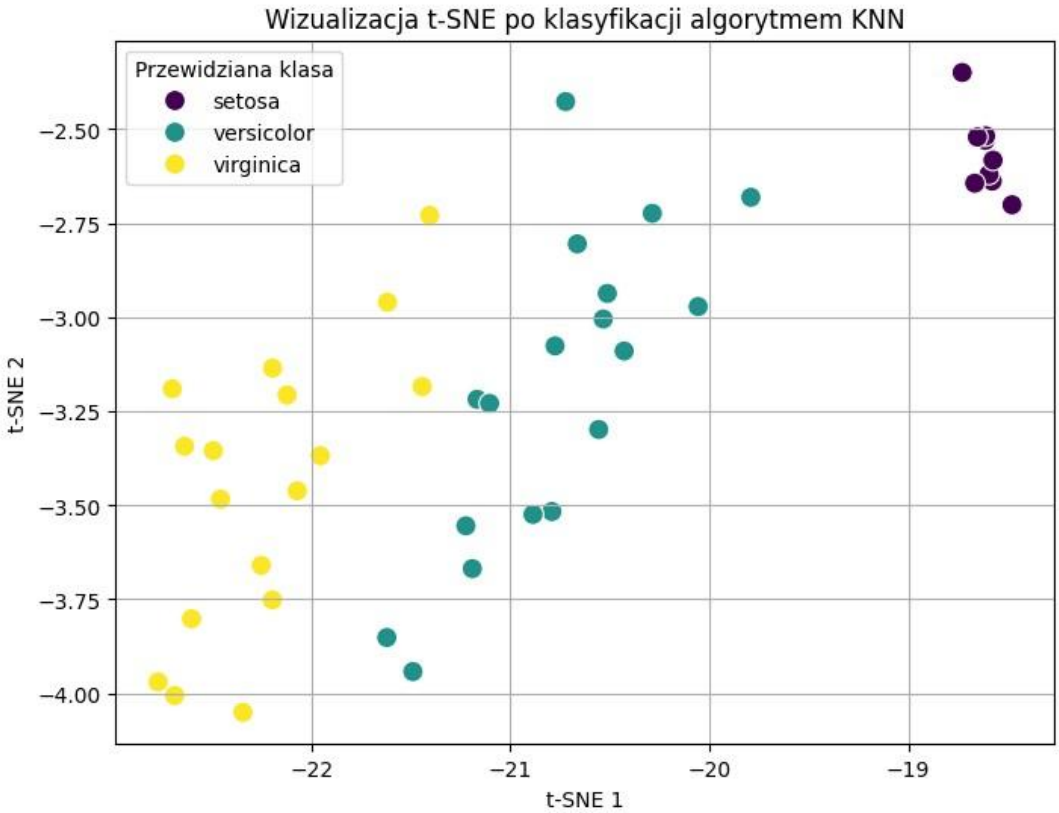

Wnioski z wykresu: Wizualizacja idealnie odzwierciedla wyniki z metryk. Ciemnofioletowa grupa (setosa) jest wyraźnie oddzielona od reszty, co tłumaczy perfekcyjne wyniki precyzji i czułości dla tej klasy. Punkty turkusowe i żółte są znacznie bliżej siebie, jednak zaimplementowany algorytm KNN wyznaczył trafną granicę decyzyjną, zachowując wysoką skuteczność działania.